

DESENVOLVIMENTO DE UM DISPOSITIVO INTELIGENTE: PARA MONITORAMENTO DE DOENÇAS DE PELE

DEVELOPMENT OF AN INTELLIGENT DEVICE FOR SKIN DISEASE MONITORING

DESARROLLO DE UN DISPOSITIVO INTELIGENTE PARA EL MONITOREO DE
ENFERMEDADES DE LA PIEL

Naum Leal Linhares Diniz¹
Kemuell Klinger Costa Torres²
Edilson Carlos Santos Lima³
Leonardo Silva Nunes⁴

RESUMO: Esse artigo buscou desenvolver um algoritmo inteligente baseado em redes neurais convolucionais para a detecção automatizada de melanoma, tipo mais letal de câncer de pele. Para isso, foi utilizada uma base de dados pública com imagens dermatoscópicas disponíveis no Kaggle. O modelo foi treinado com técnicas de *data augmentation* e pré-processamento eficiente, visando melhorar a generalização e reduzir o *overfitting*. A metodologia envolveu o uso da linguagem Python com suporte da plataforma Keras, e o experimento foi conduzido no ambiente Google Colab com uso de GPU. A base de dados foi dividida em 80% para treinamento e 20% para teste. Os resultados obtidos mostraram um desempenho promissor do modelo, com acurácia de 89,09%, sensibilidade de 85,7%, precisão de 91,3% e F1-score de 88,4%. Conclui-se que o modelo desenvolvido pode ser uma ferramenta auxiliar eficaz no diagnóstico precoce do melanoma, especialmente em contextos com acesso limitado a especialistas, contribuindo para um atendimento médico mais acessível e preciso.

3846

Palavras-chave: Melanoma. Inteligência Artificial. Redes Neurais Convolucionais.

ABSTRACT: This article aimed to develop an intelligent algorithm based on convolutional neural networks for the automated detection of melanoma, the most lethal type of skin cancer. A public dermatoscopic image dataset from Kaggle was used. The model was trained using data augmentation techniques and efficient preprocessing to improve generalization and reduce overfitting. The methodology involved the use of Python language supported by the Keras platform, and the experiment was conducted in the Google Colab environment using GPU. The dataset was split into 80% for training and 20% for testing. The results showed a promising performance, achieving an accuracy of 89.09%, sensitivity of 85.7%, precision of 91.3%, and an F1-score of 88.4%. It is concluded that the developed model can be an effective auxiliary tool for the early diagnosis of melanoma, especially in contexts with limited access to specialists, contributing to more accessible and accurate medical care

.Keywords: Melanoma. Artificial Intelligence. Convolutional Neural Networks.

¹Graduando em Sistemas de Informação, Centro universitário Santa Terezinha – CEST.

²Graduando em Sistemas de Informação, Centro universitário Santa Terezinha – CEST.

³Mst Engenharia de Computação, Professor, Centro Universitário CEST.

⁴Especialista em Engenharia de Software, Graduado em Ciência da Computação, Professor Centro Universitário CEST.

RESUMEN: Este artículo tuvo como objetivo desarrollar un algoritmo inteligente basado en redes neuronales convolucionales para la detección automatizada del melanoma, el tipo más letal de cáncer de piel. Se utilizó un conjunto de datos públicos con imágenes dermatoscópicas disponibles en Kaggle. El modelo fue entrenado utilizando técnicas de aumento de datos y preprocesamiento eficiente, con el fin de mejorar la generalización y reducir el *overfitting*. La metodología empleó el lenguaje Python con soporte de la plataforma Keras, y el experimento se realizó en el entorno Google Colab con uso de GPU. El conjunto de datos fue dividido en 80% para entrenamiento y 20% para pruebas. Los resultados demostraron un rendimiento prometedor del modelo, con una precisión del 89,09%, sensibilidad del 85,7%, precisión del 91,3% y F1-score del 88,4%. Se concluye que el modelo desarrollado puede ser una herramienta auxiliar eficaz en el diagnóstico temprano del melanoma, especialmente en contextos con acceso limitado a especialistas, contribuyendo a una atención médica más accesible y precisa.

Palavras chave: Melanoma. Inteligencia Artificial. Redes Neuronales Convolucionales.

1 INTRODUÇÃO

O câncer de pele tem se tornado um problema de saúde pública em constante crescimento, sendo o tipo de câncer mais comum no Brasil, representando cerca de 30% de todos os tumores malignos registrados no país. Entre os tipos existentes, o melanoma é considerado o mais letal, devido ao seu alto potencial de metástase, ainda que apresente altos índices de cura quando identificado precocemente. A principal causa associada ao seu surgimento está relacionada à exposição excessiva e prolongada à radiação ultravioleta (UV), principalmente durante a infância e adolescência (INSTITUTO NACIONAL DO CÂNCER, 2020).

3847

O diagnóstico precoce do melanoma pode ser feito por meio de avaliação clínica, dermatoscopia e, em casos mais complexos, biópsia. No entanto, a acurácia diagnóstica ainda depende fortemente da experiência do profissional de saúde, variando entre 65% e 80% quando baseada apenas na inspeção visual (Haenssle AL, et al., 2018; Kittler H, et al., 2002). Diante disso, o uso de tecnologias de apoio diagnóstico vem ganhando destaque como forma de ampliar o acesso a exames mais precisos e padronizados.

Entre as soluções tecnológicas, destaca-se o uso de algoritmos de inteligência artificial (IA), especialmente os baseados em redes neurais convolucionais (CNN, do inglês Convolutional Neural Networks), capazes de aprender padrões a partir de imagens dermatológicas e auxiliar na detecção automatizada de lesões malignas. Estudos recentes demonstram que esses modelos podem atingir desempenho comparável ao de dermatologistas experientes (Esteva A, et al., 2017).

2 TRABALHOS RELACIONADOS

A aplicação de inteligência artificial (IA) no diagnóstico precoce do melanoma tem sido amplamente explorada nos últimos anos. Diversos estudos têm investigado o uso de redes neurais convolucionais (CNNs, do inglês *Convolutional Neural Networks*) e técnicas de aprendizado profundo para melhorar a acurácia e eficiência dos sistemas de apoio à decisão médica. No entanto, muitos desses trabalhos ainda enfrentam desafios relacionados à generalização dos modelos e à sensibilidade às variações nas imagens dermatológicas, como iluminação, posicionamento e presença de artefatos.

2.1 Artigo 1

O estudo de Popescu et al. (2022) apresentou uma revisão sistemática sobre as novas tendências na detecção de melanoma utilizando redes neurais. O trabalho destacou a crescente adoção de métodos baseados em IA, em especial CNNs e algoritmos de segmentação, analisando bases de dados como ISIC e PH2. Além disso, o artigo enfatizou os principais desafios enfrentados por essas tecnologias, como a variabilidade nas imagens, presença de artefatos e limitações na padronização dos dados.

Como vantagem, o estudo oferece uma visão abrangente do estado da arte, servindo como referência para novas pesquisas. No entanto, uma limitação apontada pelos próprios autores é a dificuldade em propor soluções práticas para os problemas identificados. Como sugestão de trabalhos futuros, os autores mencionam a necessidade de criar modelos mais robustos e adaptáveis, que consigam manter alto desempenho mesmo diante das variações nas imagens.

3848

2.2 Artigo 2

Alsaade et al. (2021) desenvolveram um sistema de diagnóstico de melanoma utilizando duas abordagens principais: uma baseada em redes neurais artificiais (ANNs, do inglês *Artificial Neural Networks*), com extração de características via LBP (Local Binary Patterns) e GLCM (Gray-Level Co-occurrence Matrix), e outra baseada em redes convolucionais pré-treinadas, como AlexNet e ResNet50. O estudo utilizou as bases de dados PH2 e ISIC 2018, alcançando altas taxas de acurácia, chegando a 98,35%.

O trabalho demonstra o potencial das CNNs pré-treinadas combinadas com técnicas clássicas de extração de características. Entretanto, uma desvantagem relevante é a dependência

de modelos pesados, com maior custo computacional, além da pouca flexibilidade frente a conjuntos de dados menores ou com menos variabilidade. Como proposta de continuação, os autores sugerem o uso de técnicas de otimização para reduzir a complexidade dos modelos e melhorar sua aplicabilidade em ambientes clínicos reais.

2.3 Artigo 3

O estudo de Hermosilla et al. (2024) realizou uma revisão sistemática abrangente sobre o uso de redes neurais na detecção e classificação de câncer de pele. Foram analisados 45 artigos que utilizaram diferentes técnicas de visão computacional e aprendizado profundo. O estudo ressaltou o uso predominante de bases de dados como HAM10000 e ISIC, bem como as métricas de validação utilizadas, como acurácia, sensibilidade e F1-score.

Entre as vantagens, destaca-se a consolidação das principais abordagens da área, com destaque para o avanço dos algoritmos de IA no diagnóstico clínico. Contudo, o estudo apontou como desvantagem a baixa generalização dos modelos para dados fora do conjunto de treinamento, além da dificuldade de interpretação clínica dos resultados. Como proposta de continuação, os autores sugerem desenvolver modelos mais explicáveis e capazes de operar com conjuntos de dados reduzidos ou de maior diversidade.

3849

2.4 Diferencial

O diferencial do presente trabalho em relação aos estudos apresentados está na aplicação de técnicas avançadas de *data augmentation*, como rotação, zoom e espelhamento aleatório, que aumentam a robustez do modelo às variações comuns nas imagens dermatológicas. Enquanto os estudos anteriores reconhecem a limitação da variabilidade nas imagens como um obstáculo, este trabalho propõe uma solução prática para esse problema, otimizando o processo de generalização do modelo sem comprometer sua acurácia.

Outro ponto distintivo é o foco na aplicabilidade clínica. Ao utilizar arquiteturas mais leves e comparar diferentes configurações de CNNs, este estudo visa oferecer uma solução viável mesmo em contextos com infraestrutura computacional limitada. Isso contrasta com abordagens como a de Alsaade et al. (2021), que, embora muito precisas, dependem de modelos complexos e difíceis de serem implementados em larga escala.

Além disso, este trabalho prioriza o uso eficiente de conjuntos de dados menores e mais diversos, ao contrário de outros estudos que se baseiam exclusivamente em grandes bases

padronizadas. Essa escolha permite a adaptação do modelo para realidades clínicas distintas, tornando-o uma ferramenta mais acessível, versátil e prática para uso por profissionais da saúde em diferentes contextos.

3 MÉTODOS

Este estudo caracteriza-se como uma pesquisa experimental de natureza exploratória, com enfoque na aplicação de algoritmos de aprendizado de máquina para a detecção automatizada de melanoma a partir de imagens dermatológicas. Não houve interação direta com seres humanos ou animais, sendo utilizado exclusivamente um levantamento de dados, de bases públicas, o que dispensa submissão ao Comitê de Ética em Pesquisa, conforme as diretrizes da Resolução nº 510/2016 do Conselho Nacional de Saúde.

As imagens utilizadas foram obtidas da plataforma pública Kaggle (<https://www.kaggle.com/>), que oferece bases de dados rotuladas por profissionais da área de saúde. A base selecionada contém cerca de 10.000 imagens dermatoscópicas, abrangendo diferentes tipos de lesões, incluindo tumores malignos e benignos. Deste total, 9.000 imagens foram utilizadas para treinamento e validação do modelo, enquanto 1.000 foram reservadas para testes.

3850

O modelo desenvolvido é baseado em redes neurais convolucionais (CNNs), implementado em linguagem Python utilizando bibliotecas como Keras e TensorFlow. O pré-processamento das imagens incluiu redimensionamento, normalização e aplicação de técnicas de *data augmentation*, como rotação, deslocamento, zoom e espelhamento, com o objetivo de aumentar a variabilidade e reduzir o risco de *overfitting*.

A divisão da base foi feita com 80% das imagens destinadas ao treinamento e 20% ao teste. O treinamento foi realizado na plataforma Google Colab, com suporte de unidades de processamento gráfico (GPUs), visando acelerar o processo de aprendizado. As métricas utilizadas para avaliação do modelo incluíram acurácia, sensibilidade, precisão e F1-score, seguindo os padrões da área de aprendizado de máquina.

Por fim, a pesquisa foi conduzida com o apoio da infraestrutura do Laboratório de Pesquisa do curso de Sistemas de Informação do Centro Universitário Santa Teresinha (CEST), utilizando equipamentos computacionais locais e ferramentas gratuitas disponíveis na internet.

4 RESULTADOS

O algoritmo desenvolvido foi treinado e testado com um conjunto de mil imagens dermatoscópicas, oriundas de uma base de dados pública contendo diferentes tipos de imagens de melanoma. Após o treinamento do modelo, os resultados demonstraram uma acurácia de 89,63%, sensibilidade de 91,07%, precisão de 88,15%, F1-score de 89,59% e função de perda (loss) de 10,38%. Esses valores representam o desempenho do modelo nas tarefas de classificação das imagens dermatológicas (Tabela 1).

Para fornecer uma análise complementar da confiabilidade do sistema, foi aplicado o Teorema de Bayes aos dados obtidos. Com isso, foi possível calcular a probabilidade condicional de o diagnóstico positivo ser, de fato, verdadeiro, alcançando uma probabilidade posterior de 97,78%. A probabilidade de erro (classificação incorreta) foi de 2,22% (Tabela 2).

Tabela 1 - Desempenho do modelo de rede neural convolucional no diagnóstico de melanoma.

Métrica	Valor (%)
Acurácia	89,63
Sensibilidade	91,07
Precisão	88,15
F1-score	89,59
Função de Perda	10,38

3851

Fonte: Elaborado pelos autores, 2025. Dados extraídos de Kaggle – Melanoma Classification Dataset.

Tabela 2 - Matriz de Confusão do Modelo de Detecção de Melanoma.
Base de dados: Kaggle, 2024.

	Preditiva: Positivo	Preditiva: Negativo	Total
Classe: Positivo	357 (VP)	35 (FN)	392
Classe : Negativo	48 (FP)	360 (VN)	408
Total Predito	405	395	800

Fonte: Elaborado pelos autores, 2025. Dados extraídos da base pública Kaggle – Melanoma Dataset.

Legenda:

VP: Verdadeiro Positivo

FN: Falso Negativo

FP: Falso Positivo

VN: Verdadeiro Negativo

O modelo desenvolvido com redes neurais convolucionais apresenta desempenho satisfatório na detecção automatizada de melanoma, com métricas como acurácia (89,63%), sensibilidade (91,07%) e F1-score (89,59%) mostrando equilíbrio entre a correta identificação de lesões e a redução de falsos positivos. Esses valores indicam que o algoritmo possui potencial para ser uma ferramenta de apoio na triagem clínica, especialmente em contextos com acesso limitado a especialistas.

Comparando com a literatura, o estudo de Popescu et al. (2022) destacou desafios como artefatos nas imagens e variabilidade nos dados. Nosso modelo supera parte desses obstáculos por meio da aplicação de Data Augmentation (rotação, zoom, espelhamento aleatório), aumentando a robustez e a capacidade de generalização. Já Alsaade et al. (2021) utilizaram redes pré-treinadas e obtiveram altos índices de acurácia, mas com foco em bases maiores e mais padronizadas. Nosso diferencial está na boa performance mesmo com conjuntos menores e mais diversos, o que o torna mais aplicável à realidade de centros clínicos com recursos limitados. Além disso, o trabalho de Hermosilla et al. (2024) reforça a importância de melhorar a precisão dos modelos de IA — o que também foi uma das preocupações abordadas em nosso estudo com o uso de múltiplas métricas de avaliação e validação estatística via Teorema de Bayes.

3852

Apesar dos avanços, o estudo apresenta limitações que precisam ser consideradas. A base de dados utilizada continha majoritariamente imagens de melanoma, não abrangendo outras lesões cutâneas comuns, como carcinoma basocelular ou queratose actínica. Além disso, a qualidade das imagens influenciou diretamente no desempenho do modelo, evidenciando a importância de técnicas mais refinadas de pré-processamento. Outro ponto crítico é a dependência de um ambiente computacional externo, o que ainda limita a aplicabilidade do sistema em tempo real.

Como perspectivas futuras, propõe-se a ampliação da base de dados com maior diversidade étnica e diferentes tipos de lesões, o desenvolvimento de um sistema embarcado que permita análise local das imagens e a realização de estudos clínicos com profissionais da

área para validar a eficácia do modelo na prática médica. Tais avanços serão fundamentais para consolidar o uso da inteligência artificial como suporte ao diagnóstico precoce do câncer de pele.

CONSIDERAÇÕES FINAIS

O presente estudo demonstrou a eficácia de um modelo baseado em redes neurais convolucionais para a detecção automatizada do melanoma, alcançando bons resultados de desempenho, com acurácia de 89,63% e F1-score de 89,59%. A utilização de técnicas de Data Augmentation foi fundamental para melhorar a generalização do modelo, mesmo com uma base de dados limitada.

Como diferencial, o estudo incorporou o Teorema de Bayes na análise, aumentando a confiabilidade dos resultados em contextos clínicos. Apesar dos avanços, limitações como a restrição a imagens de melanoma e a dependência de infraestrutura externa para processamento apontam a necessidade de futuras melhorias.

Conclui-se que o modelo tem potencial para ser uma ferramenta de apoio ao diagnóstico precoce de doenças de pele, especialmente em locais com poucos recursos, contribuindo para a redução de diagnósticos tardios e, consequentemente, da mortalidade por melanoma.

AGRADECIMENTOS E FINANCIAMENTO

3853

Este trabalho foi realizado com apoio do Centro Universitário Santa Terezinha (CEST), da Fundação de Amparo à Pesquisa e ao Desenvolvimento Científico e Tecnológico do Maranhão (FAPEMA), por meio do Programa Institucional de Iniciação Científica (PIBIC).

REFERÊNCIAS

ALSADE AA, et al. Melanoma recognition using artificial neural networks with extracted features and deep convolutional neural networks. *Journal of Healthcare Engineering*, 2021; 2021:1–9.

BAPTISTA BR. Inteligência artificial na medicina: desafios e oportunidades. *Revista Brasileira de Informática em Saúde*, 2002; 8(1):45–52.

HERMOSILLA J, et al. Deep learning for skin cancer detection: A systematic review of recent advances and clinical relevance. *Medical Image Analysis*, 2024; 89:102–119.

POPEESCU D, et al. A review of convolutional neural networks applied to melanoma detection. *Journal of Imaging*, 2022; 8(4):98–115.

SOUZA DF, BARCELOS GF. Processamento digital de imagens aplicado à dermatologia. *Revista Brasileira de Engenharia Biomédica*, 2012; 28(3):175–182.